SAPIENZA
UNIVERSITÀ DI ROMA

Un supersense tagger basato su BabelNet e Wikipedia

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica
Corso di laurea in Informatica

Candidato
Biagio La Rosa
1389823

Responsabile
Roberto Navigli

A/A 2015/2016

Indice

1 Introduzione **4**

2 La disambiguazione automatica **6**

2.1 Risorse 8

2.1.1 Wikipedia 8

2.1.2 WordNet 11

2.2 La disambiguazione dei sensi di una parola 12

2.3 Supersense tagging 14

2.4 Obiettivi del sistema 16

3 Il sistema **17**

3.1 Le componenti del sistema 17

3.1.1 It Makes Sense 17

3.1.2 Strumenti Ausiliari 19

3.2 Generalizzazione 20

3.2.1 L'algoritmo di generalizzazione 22

3.3 Classificazione 24

3.3.1 Creazione Training Set 25

3.3.2 Apprendimento automatico 27

3.3.3 Generazione nuovo testo annotato 30

4 Valutazione del sistema **31**

4.1 Risultati 31

4.2 Conclusione e sviluppi futuri 39

Bibliografia **42**

Capitolo 1

Introduzione

I sistemi che accettano linguaggio naturale in input, come i sistemi di traduzione o di estrazione automatica di informazioni, hanno l'esigenza di definire il significato della frase di input per funzionare correttamente. Tuttavia, poiché il significato di una frase è dato dalla composizione delle sue parole, qualsiasi sistema che spera di processare i linguaggi naturali come le persone deve avere informazioni sulle parole e sul loro significato [1].
Il significato delle parole è fornito dai dizionari ma talvolta una stessa parola, nel caso delle cosiddette *parole polisemiche*, può avere diversi significati in base al contesto in cui è usata. La sola consultazione del dizionario non è quindi sufficiente, ma occorre un processo di disambiguazione affinché il sistema individui il significato corretto.

La **disambiguazione** è il processo tramite cui si definisce il significato specifico di una parola polisemica e rappresenta uno dei problemi aperti dell'intelligenza artificiale, in particolar modo dell'elaborazione del linguaggio naturale e della computazione linguistica. Ad esempio la parola "albero" può

indicare:

- una pianta;
- il palo verticale delle barche;
- una parte meccanica del motore;
- etc.

e in base al significato ha traduzioni diverse: nella lingua inglese infatti la pianta viene tradotta con "tree", "mast" è l'albero delle barche e "crankshaft" l'albero motore; il mancato trattamento del significato può quindi portare ad errori grossolani nella fase di traduzione.

Il **supersense tagging** (abbreviato con SST) si colloca nel contesto della disambiguazione e si pone l'obiettivo di annotare ogni parola tramite una tassonomia predefinita, ovvero di associare ad ogni lemma un elemento della tassonomia chiamato **Supersense**. Un supersense è una classe lessicografica con la quale altre parole possono avere una relazione semantica del tipo *is-a/è-un*. Due parole hanno una relazione is-a se una delle due è l'iperonimo dell'altra, cioè se «una delle due rappresenta un'unità lessicale di significato più generico ed esteso rispetto all'altra che è in essa inclusa» [2]. Ad esempio "gatto" potrebbe avere una relazione is-a con "animale".

Capitolo 2

La disambiguazione automatica

Le macchine, per poter disambiguare le parole, hanno bisogno di processare il testo e convertirlo in dati strutturati che possano essere analizzati. Diversi fattori possono variare in questo processo: la rappresentazione dei sensi, la natura del testo, le fonti di conoscenza e il metodo di classificazione.
Come riassunto in [3] i sensi di una parola possono essere rappresentati o in maniera *enumerativa*, elencando i diversi sensi che può assumere una parola (ad esempio in un dizionario), o tramite approcci *generativi* cioè che estrapolano il significato da strutture che "raccontano" qualcosa sul lemma preso in considerazione (ad esempio chi esegue l'azione, da cosa è composto, a cosa appartiene etc.).
Le fonti di conoscenza si dividono in *risorse strutturate*, come dizionari e ontologie, e *risorse non strutturate*, come testo libero, che possono contenere annotazioni o collezioni di risorse (etichette, parole, informazioni).
Per *metodo di classificazione* si intende il metodo con il quale si istruisce il sistema a riconoscere e classificare le entità con gli elementi della tassonomia

corrispondenti. Ci sono due approcci principali per la classificazione:

- *Apprendimento supervisionato*: quando si fornisce inizialmente al sistema un insieme di esempi definito *training set*, costituito da coppie *(i,o)* dove i è un istanza di input e o è l'output desiderato per l'istanza i, dal quale il sistema elabora una funzione che ha l'obiettivo di predire l'output di un insieme di input sconosciuti fino a quel momento definito *testing set*.

- *Apprendimento non supervisionato*: quando viene fornito solo il training set e il sistema classifica ed estrae caratteristiche comuni autonomamente. Spesso in questo caso i significati non sono note a priori ma fanno parte delle previsioni del sistema.

La scelta del metodo di classificazione è strettamente legato alle risorse disponibili: ad esempio un apprendimento supervisionato ha bisogno di testo annotato o risorse strutturate, mentre per uno non supervisionato è sufficiente testo non strutturato.

L'apprendimento inoltre si definisce *basato su parola* se, dato un lemma, tutti gli esempi che vengono forniti al classificatore in fase di training sono istanze di quel lemma annotato, *basato su classi* se gli esempi sono istanze di una delle classi del lemma ma non contengono necessariamente il lemma stesso come istanza annotata.
Un approccio basato su classi ha l'importante vantaggio di aumentare il numero di esempi disponibili per ogni training set ma ha lo svantaggio del rumore nei dati causato dal raggruppamento di parole diverse nello stesso set [4].

Per valutare l'apprendimento e confrontare gli approcci sono utili alcune metriche mostrate nel prossimo esempio. Si ipotizzi il caso della classificazione binaria con possibili valori TRUE o FALSE. Siano i_1 l'input e o_1 l'output.
Si consideri innanzitutto il caso in cui o_1=TRUE sia l'output desiderato. Se il sistema restituisce correttamente TRUE, o_1 è un "vero positivo", altrimenti un "falso negativo".
Sia ora o_1=FALSE l'output desiderato. In questo caso se il sistema restituisce TRUE si ha un "falso positivo", altrimenti un "vero negativo".
I coefficienti di "falso negativo", "falso positivo", "vero negativo" e "vero positivo" sono utili per calcolare le seguenti metriche:

- **accuratezza**: la percentuale delle istanze classificate correttamente;
- **precisione**: la percentuale dei valori positivi classificati correttamente;
- **richiamo**: il tasso di veri positivi;
- **punteggio $\mathbf{F_1}$**: la media armonica tra precisione e richiamo.

2.1 Risorse

2.1.1 Wikipedia

Wikipedia è una enciclopedia multilingua online gratuita nata nel 2001 e redatta da milioni di volontari da ogni parte del mondo e può essere considerata come un esempio di testo libero parzialmente strutturato. Sostenuta da Wikimedia Foundation è, con 35mln di voci, l'enciclopedia più grande mai

scritta e uno dei 10 siti web più visitati al mondo. Nonostante sia liberamente modificabile da chiunque, Wikipedia ha raggiunto standard di qualità e accuratezza paragonabili a quelli delle enciclopedie tradizionali redatte da esperti [5] e per questa ragione rappresenta un valido strumento come contenitore di conoscenza per i sistemi di elaborazione del linguaggio naturale.
Wikipedia offre un buon compromesso tra quantità e qualità, superando i problemi degli approcci tradizionali basati su ontologie manuali di alta qualità, ma limitate nella copertura dei lemmi o nella quantità di frasi, o su testo libero disponibile in grandi quantità ma poco strutturato. Grazie ad alcune caratteristiche come ad esempio le categorie, i link, i metadata, etc. Wikipedia fornisce oltre al testo anche una struttura per classificare lo stesso [6]. Non bisogna tuttavia dimenticare che per la sua stessa natura non è esente da errori e rappresenta una fonte di conoscenza meno precisa di quelle manuali.
Come le enciclopedie tradizionali è costituita da un insieme di articoli, scritti seguendo delle linee guida così da promuovere consistenza e coesione tra essi. Ogni articolo possiede un titolo, può contenere uno o più link che esprimono relazioni con altri articoli e descrive un singolo concetto.
Per i termini ambigui offre le "pagine di disambiguazione", ovvero pagine che contengono tutti gli articoli che possono riferirsi ad un determinato lemma con i relativi significati. Talvolta il significato o il dominio di un lemma può essere espresso anche nel titolo tramite parentesi tonde per distinguerlo dagli altri sensi; ad esempio "Pilot (aeronautics)" indica il pilota di aerei chiaramente distinguibile da "Pilot (television program)".
Un esempio di articolo tratto da Wikipedia con le caratteristiche descritte sino ad ora è presentato nella figura 2.1.

León (historical region)

From Wikipedia, the free encyclopedia

The **region of León** or **Leonese region** (Leonese: *rexón de Llión*, Spanish: *región de León* and Asturian: *rexón de Llión*) is a historic territory defined by the 1833 Spanish administrative organisation. The Leonese region encompassed the provinces of Salamanca, Zamora, and León, now part of the modern Spanish autonomous community of Castile and León. As is the case with other historical regions, and continuing with centuries of history, the inhabitants of the Leonese region are still called Leonese.[citation needed] Even today, according with official autonomous government, the historical territorial adjective is used in addition with the modern annexed territory, the rest of Old Castile, being "Castilians and Leonese".

Historic regions of Spain. León is in violet near upper left.

Contents [hide]

1 Leonese history
2 Present
3 Leonese language
4 See also
5 External links

Leonese history [edit]

Until 1833, the formerly independent Kingdom of León, situated in the northwest region of the Iberian Peninsula, retained the status of a kingdom although dynastic union had brought it into the Crown of Castile. The Kingdom of León was founded in 910 A.D. when the Christian princes of Asturias along the northern coast of the peninsula shifted their main seat from Oviedo to the city of León. The Atlantic provinces became the Kingdom of Portugal in 1139, and the eastern, inland part of the kingdom was joined dynastically to the Kingdom of Castile first in 1037–1065, again 1077–1109 and 1126–1157, 1230–1296 and from 1301 onward (see Castile and León § Historic union of the Kingdoms of Castile and León). León retained the status of a kingdom until 1833, being replaced by *Adelantamientos Mayores*, where the Leonese Adelantamiento consisted of the territories between the Picos de Europa and the Duero river.

In 1188 the Kingdom of León developed the Cortes of León, one of the earliest Parliaments in Europe, and in 1202 a legislation about economics.

Figura 2.1: Articolo Leòn di Wikipedia.en

Altre caratteristiche di Wikipedia sono le pagine di redirezione e le categorie. Le pagine di redirezione non hanno testo ma contengono un link di redirezione ad una pagina che il sistema valuta più attinente alla ricerca effettuata. Ad esempio quando si cerca il plurale dei lemmi si viene redirezionati automaticamente alla pagina contenente il lemma al singolare.
Per quanto riguarda le categorie, attualmente Wikipedia ne possiede circa 400000, ognuna contenente una media di 19 articoli [6], liberamente creabili e modificabili come il resto dell'enciclopedia.

Grazie agli elementi sopra elencato può essere usata, oltre che come enciclopedia, anche per lo studio delle caratteristiche delle lingue (ad esempio analizzando la distribuzione statistica delle parole), come aiuto per la traduzione automatica, poiché spesso uno stesso articolo in due lingue diverse contiene le stesse frasi semplicemente tradotte, per sistemi di domanda-risposta

e per sistemi di estrazione automatica di relazioni semantiche sfruttando i link all'interno degli articoli.

2.1.2 WordNet

WordNet è un database lessicale per la lingua inglese, creato da G. Miller e il Laboratorio di Scienze cognitive dell'università di Princeton, ampiamente utilizzato per la linguistica computazionale e l'elaborazione del linguaggio naturale [1]. E' il tipico esempio di ontologia.
Nella sua attuale versione (3.1) conta circa 150000 parole suddivise in 117000 synsets, ossia strutture che riuniscono parole simili che esprimono lo stesso concetto. Ogni synset appartiene a una delle 44 classi lessicografiche predefinite e fornisce informazioni sul concetto che esprime attraverso la definizione, la categoria di appartenenza e le relazioni semantiche e lessicali con altri sensi (iponimi, meronimi, iperònimi, sinonimi etc.).
Nonostante sia di fatto lo standard per i sistemi di disambiguazione, WordNet presenta alcuni problemi; come descritto in [7] la granularità dei sensi non è omogenea e anzi spesso differisce anche dentro lo stesso dominio (ad esempio "dog" viene trattato in maniera più specializzata di "cat" anche se ciò non corrisponde alla realtà), la copertura dei termini è limitata, la consistenza nel classificare le categorie è bassa e capita di avere oggetti nella realtà molto simili appartenere a categorie diverse e infine la grana in genere troppo fine rende difficoltosa la disambiguazione.

Prendendo ispirazione da WordNet e il suo successo sono nati diversi progetti satellite in altre lingue come MultiWordNet[1], EuroWordNet[2], etc. Per

[1] http://multiwordnet.fbk.eu/english/home.php
[2] http://www.illc.uva.nl/EuroWordNet/

collegare le diverse versioni e renderle utilizzabili per facilitare la traduzione automatica è stata creata un'associazione chiamata Global WordNet Association[3]

2.2 La disambiguazione dei sensi di una parola

La **WSD (Word Sense Disambiguation)** è una delle attività più difficili della linguistica computazionale poiché riguarda da vicino la complessità dei linguaggi. Un riassunto della storia della disambiguazione e delle metodologie è stato raccolto in [3] e [8]. Il problema maggiore riguarda le parole polisemiche e nasce dalla granularità troppo fine dei sensi nei linguaggi.
I due approcci all'apprendimento automatico producono risultati tipicamente diversi e non confrontabili. Infatti mentre gli approcci supervisionati hanno l'obiettivo di annotare ogni parola con uno dei suoi sensi basandosi sui dizionari che li forniscono, quelli non supervisionati non fanno riferimento né a risorse annotate né a dizionari e il loro lavoro può essere visto come una "discriminazione" tra parole, dividendo le occorrenze di una parola in più insiemi affinché all'interno dello stesso insieme vi siano solo quelle che il sistema crede siano espressione dello stesso senso. La conseguenza è che l'insieme dei sensi così individuati raramente rispecchia quello dei dizionari, a maggior ragione se si pensa che ogni dizionario può fornire un numero diverso di sensi per ogni parola. Generalmente i sistemi supervisionati hanno ottenuto risultati migliori negli esercizi internazionali di valutazione, come le edizioni del Senseval[4] [4], tuttavia hanno il grosso problema di aver bisogno

[3] http://globalwordnet.org/
[4] http://www.senseval.org/

di un'ingente quantità di testo annotato che raramente è disponibile per tutte le lingue.

La risorsa più usata per la disambiguazione è senza dubbio WordNet ma a causa della granularità troppo fine dei suoi sensi ha portato a risultati non sempre soddisfacenti: basti pensare che l'accuratezza del 72,5% ottenuta da Snyder e Palmer [9] al SensEval-3 è un risultato difficile da battere anche per i sistemi di disambiguazione attuali [10]. Per arginare questo problema diversi gruppi di ricerca hanno cercato di rendere la grana di WordNet più grossa raggruppando sensi della stessa parola [11] e ottenendo un miglioramento delle performance grazie alla riduzione della polisemia (ad esempio in [12] si è passati da 3.14 a 2.09 sensi per parola ottenendo un punteggio F_1 del 78% a fronte del 65% di partenza con il sistema GAMBL [13]).
Un'alternativa a WordNet è rappresentata da Wikipedia che viene usata sempre più estensivamente nelle attività di disambiguazione.
Esempi di alcuni lavori eseguiti usando Wikipedia come fonte di conoscenza si possono trovare riassunti in [6]. Tra questi riportiamo brevemente l'approccio di Mihalcea in [14] dove gli articoli vengono usati come sorgente di testo annotato da utilizzare in un apprendimento supervisionato coadiuvato da WordNet e in [15] dove, oltre che come testo annotato, Wikipedia viene usata anche come dizionario ottenendo risultati soddisfacenti (87% come punteggio F_1).
Infine altri gruppi di ricerca si sono concentrati a costruire insiemi predefiniti di classi sotto le quali raggruppare più sensi anche di parole diverse semplificando così ulteriormente la disambiguazione, usando una granularità notevolmente più grossa dei tentativi precedenti, come ad esempio nel supersense tagging.

2.3 Supersense tagging

La differenza principale tra **supersense tagging (SST)** e Word Sense Disambiguation è che nel primo caso abbiamo un insieme limitato di classi predefinite, mentre nel secondo cambia a seconda della parola e varia all'interno dell'intero lessico. Di conseguenza il supersense tagging ha una grana più grossa ed è più trattabile della disambiguazione e per questo raggiunge molto spesso un'accuratezza maggiore. Il supersense tagging può essere considerato come una forma ridotta di disambiguazione nella quale i sensi possibili per una data parola sono minori e meno specifici e allo stesso tempo come una versione estesa del NER (Named Entity Recognition), un'attività della computazione linguistica nella quale si classificano i nomi propri con un insieme ristretto di categorie possibili.

Nel corso degli anni sono stati provati diversi approcci usando risorse e testi annotati differenti. I primi lavori riguardarono la lingua inglese, poiché il materiale disponibile è maggiore rispetto alle altre lingue, e presero ispirazione dal lavoro di Ciaramita e Johnson [16] i quali produssero un framework usando le 26 classi lessicografiche di WordNet per generalizzare i nomi, WordNet come dizionario e un classificatore multiclasse neurale Perceptron per l'apprendimento automatico supervisionato. I supersense usati in questo lavoro sono stati ampiamente utilizzati nella ricerca ma anche l'approccio fu ripreso, ad esempio in [17] dove il supersense tagger presentato ottenne un F_1[5] di 77% basandosi su dataset SemCor, un testo annotato con i supersense di WordNet, e 70% su dataset Senseval-2; la novità di questo lavoro fu l'estensione ai verbi e l'uso di un modello di Markov nascosto trattando il supersense tagging come un problema di sequenza di etichette. Un miglioramento ulteriore

[5] https://en.wikipedia.org/wiki/F1_score

fu ottenuto in [18] applicando i CRF (campi casuali condizionali) ottenendo uno score di 80%.
Tra i risultati di maggior rilievo per il SST applicato a lingue diverse dall'inglese ricordiamo quelli illustrati in [19] ottenuti usando Italian Syntactic-Semantic Treebank come risorsa annotata, WordNet come dizionario e Maximum Entropy come classificatore e ottenendo un punteggio F_1 del 79% per la lingua italiana e in [20] dove venne presentato un supersense tagger per l'arabo usando una mappatura tra Wikipedia in versione Araba e WordNet. Tipicamente il supersense tagging si è focalizzato sui nomi e verbi, ma ultimamente si è esteso anche agli aggettivi [21].
Risultati degni di nota, infine, sono stati raggiunti anche con approcci non supervisionati come in [7] nel quale usando la similarità semantica per calcolare i supersense si ottenne un'accuratezza del 68%.

Il campo principale di applicazione del SST è l'estrazione delle informazioni dai testi e nei sistemi di domanda-risposta, ma può anche essere usata come aiuto in molte altre attività dell'elaborazione del linguaggio tra le quali il riconoscimento delle metafore [22], la disambiguazione delle preposizioni [23] e l'estrazione di relazioni [24].

Oltre al supersense tagging (legato sopratutto a WordNet) si sono diffusi approcci simili ma basati su diverse relazioni, classi e fonti di conoscenza come WordNet Domains [25], SUMO [26] e Basic Level Concepts [27].

2.4 Obiettivi del sistema

Il sistema qui presentato si pone l'obiettivo di applicare il supersense tagging a testo libero (Wikipedia), annotandolo innanzitutto con i supersense di BabelNet e producendo nuovo testo annotato tramite la tecnica dell'apprendimento supervisionato. Nel nostro sistema applicheremo il supersense tagging esclusivamente ai nomi, riducendo quindi i possibili significati di una data parola. Gli obiettivi che si pone il sistema sono:

- *annotazione dei link di Wikipedia con i supersense di BabelNet*: tramite l'algoritmo di generalizzazione, come descriveremo nella sezione 3.2.1, potremo annotare i link di Wikipedia con i supersense estratti da BabelNet sfruttando esclusivamente la duttilità di quest'ultimo e l'algoritmo;

- *generazione di nuovo testo annotato con i supersense di BabelNet*: tramite il supersense tagger qui presentato infatti potremo produrre una grande mole di testo annotato con gli stessi supersense del punto precedente derivante dall'applicazione dello stesso su Wikipedia e considerando i risultati dove il classificatore è più sicuro come vedremo nella sezione 3.3.3;

- *offrire un framework multilinga* facilmente adattabile usando risorse e strumenti capaci di lavorare con molteplici lingue come BabelNet e Wikipedia;

- *miglioramento dei supersense di BabelNet* aggiungendo o rimuovendo classi osservando i risultati di classificazione e generalizzazione trattato nella sezione 3.2.

Capitolo 3

Il sistema

In questo capitolo viene presentato il sistema descrivendo le componenti, come esse interagiscono tra loro e il processo di classificazione. Il sistema è il risultato dell'integrazione tra: It Makes Sense (3.1.1) usato come sistema di disambiguazione per costruire i modelli e predire i supersense, Wikipedia come database di frasi, BabelNet come rete semantica e dizionario tramite cui annotare le frasi di Wikipedia per renderle utilizzabili in It Makes Sense, e infine alcuni tools utili per lo sviluppo o la validazione del sistema.

3.1 Le componenti del sistema

3.1.1 It Makes Sense

It Makes Sense (IMS) è un sistema di disambiguazione basato su apprendimento automatico supervisionato per le parole inglesi implementato in Java.

Fornisce un framework flessibile ed estensibile, supporta diversi classificatori e possiede tools integrati utili, come il POS Tagger o il lemmatizzatore, che altrimenti avrebbero richiesto ulteriori task di lavoro.
Grazie a queste caratteristiche è stata implementata una nuova feature nel sistema che discrimina tra parole che hanno il primo carattere maiuscolo e parole che lo hanno minuscolo portando un miglioramento dell'accuratezza di circa il 2% .
Nel presente sistema è stato usato LibLibear Classifier come classificatore, basato su SVM (Support Vector Machines) e la libreria LibLinear, in quanto con un elevato numero di esempi testuali per ogni training set, come osservato in [28], LibLinear ha delle prestazioni migliori rispetto a SVM semplice.

Come illustrato da Zhi Zhong e Hwee Tou Ng in [29] IMS divide il lavoro in 3 fasi:

1. pre-processamento;
2. estrazione caratteristiche;
3. classificazione.

Nella fase di pre-processamento il testo viene diviso in frasi a cui vengono assegnati POS tags, etichette che associano ad ogni parola una Part-of-Speech (nome, verbo, etc.), e viene memorizzata la forma del lemma.
Una volta pre-trattato il testo, IMS procede alla costruzione del vettore delle caratteristiche. In particolare vengono aggiunte al vettore i POS Tags delle parole vicine al lemma, le parole stesse, la loro combinazione e, come detto precedentemente, un valore booleano che indica se il lemma inizia con una lettera maiuscola o minuscola.

I vettori vengono convertiti in un formato leggibile dal classificatore e sono pronti ad essere usati nella fase di classificazione trattata nella sezione 3.3.2.

3.1.2 Strumenti Ausiliari

Oltre alle componenti del sistema illustrate in precedenza, sono stati utilizzati altri strumenti che, benché non rappresentino degli elementi chiave del sistema, hanno contribuito al suo sviluppo e controllo. Meritano una citazione in particolare:

- **Evo Inflector Master** un tool per la pluralizzazione delle parole inglesi creato da Slawek Piotrowski e basato sul paper di Damian Conway [30]. Questo tool offre un'accuratezza del 100% sulle 1000 parole usate più frequentemente in inglese e del 70% in totale. Benché l'accuratezza non sia eccelsa questa comprende anche aggettivi,verbi etc. che nel nostro sistema non verranno mai pluralizzati ed è stato ritenuto sufficiente per l'impiego nel sistema.

- **Stanford POS Tagger** un software che legge testo in qualche linguaggio e assegna parti del discorso ad ogni parola [31]. Non è stato utilizzato nel classificatore in quanto IMS ne possiede uno già integrato, tuttavia è risultato utile per validare i risultati della classificazione. Applicato a testo non annotato di Wikipedia ha permesso di estrarre statistiche per valutare il corretto funzionamento del sistema.

3.2 Generalizzazione

Con il termine **generalizzazione** si intende il processo tramite il quale si associa un lemma ai sui eventuali supersense. Per generalizzare un lemma abbiamo bisogno di un insieme di supersense e una rete semantica che colleghi i lemmi eventualmente a tali sensi, entrambi forniti da BabelNet.

BabelNet, ideato da Roberto Navigli, è un dizionario enciclopedico multilingua ed una rete semantica che collega tra loro diversi concetti, costituito da 14 milioni di nodi chiamati *Babel Synsets*. Ogni nodo rappresenta un concetto e contiene un insieme di sinonimi che esprimono il concetto in diverse lingue [32].
BabelNet supporta, nella versione 3.6, 271 lingue ed è il risultato di un'integrazione automatica di 13 sorgenti tra le quali le più importanti Wikipedia e WordNet.
Rappresenta la conoscenza come un grafo diretto G = (V,E) dove V sono i concetti ed E le relazioni semantiche tra i nodi V; le relazioni supportante sono molteplici, tuttavia il sistema fa uso esclusivamente delle relazioni is-a.
Un'altra caratteristica fondamentale è la mappatura tra Wikipedia e WordNet e più in generale con le altre enciclopedie: ogni nodo può contenere sensi provenienti da diverse sorgenti e questo ci permetterà di spostarci da una fonte di conoscenza all'altra agilmente e di avere informazioni più complete rispetto ad usare una sola di queste risorse.
BabelNet ci offre gli strumenti necessari al supersense tagging:

- un dizionario tramite cui dato un lemma è possibile estrarre i possibili significati;

- una rete semantica tramite cui collegare i lemmi;
- integrazione di Wikipedia grazie alla quale possiamo collegare i link interni di Wikipedia alla rete semantica;
- una struttura utile all'eventuale estensione del sistema (per supporto multilingua, domini, etc.).

L'insieme $\mathcal{SS}$ **dei supersense** del sistema è stato individuato in 2962 nodi selezionando quelli con più connessioni semantiche e che rappresentano categorie di oggetti, eliminando quei supersense che rappresentano domini o parole troppo specifiche come "gatto persiano".
Le classi presentano una granularità fine e, non essendo disgiunte, possono avere anche relazioni is-a tra esse o sovrapposizioni: ciò è motivato dal voler coprire quanti più lemmi possibili ma allo stesso tempo generalizzare in maniera quanto più specifica possibile.
A titolo di esempio consideriamo il Babel Sense Stephen Hawking avente due relazioni is-a con rispettivamente "uomo" e "fisico": poiché siamo interessati ad un grado di specificità elevato vorremmo che la generalizzazione restituisse fisico come supersense. Se però volessimo un insieme di classi disgiunte saremmo costretti a scegliere solo una tra le due, quindi dovremmo eliminare "uomo" e, conseguentemente, perdere informazione per tutti quei Babel Sense che hanno relazioni is-a solo con uomo (ad esempio Kobe Bryant). E' stato deciso quindi di tenere entrambi i supersense sacrificando la precisione del classificatore che, in questi casi, dovrà scegliere il supersense adatto tra significati simili.

La **rete semantica** è stata ottenuta da un sotto-insieme delle relazioni is-a di BabelNet ignorando le relazioni generate automaticamente dall'integra-

zione su BabelNet delle diverse sorgenti: abbiamo mantenuto quindi le relazioni provenienti di WibiTaxonomy, WordNet e WikiData che assicurano un'elevata precisione grazie a controlli manuali eseguiti su queste sorgenti.

3.2.1 L'algoritmo di generalizzazione

Dato un lemma lo scopo dell'algoritmo di generalizzazione è restituire gli eventuali supersense associati.
Esso effettua innanzitutto una visita del grafo in ampiezza denominata BFS (Breath-first search) che ha l'importante «proprietà di espandere la frontiera fra i vertici scoperti e quelli da scoprire in maniera uniforme lungo l'ampiezza della frontiera, ovvero l'algoritmo scopre tutti i vertici che si trovano a distanza k dal nodo di partenza, prima di scoprire i vertici a distanza k+1»[33], permettendo di individuare il supersense più vicino al lemma che si vuole generalizzare che chiameremo **pivot**.
Una volta individuato il pivot l'algoritmo esegue una nuova BFS dal nodo del lemma generando un albero di visita potato ad un altezza predefinita (7): all'interno di esso verranno cercati altri supersense in relazione con il nodo pivot che, avendo una relazione is-a con esso, rappresentano sensi più specifici per il lemma; tra questi vengono selezionati i supersense che si trovano al livello più basso dell'albero. Di seguito lo pseudo codice dell'algoritmo:

$GENERALIZZZA\,(t : nodo, SS : supersense)$

1 $V = \emptyset \qquad // \, nodi\, visitati$

2 $Q = \emptyset \qquad // \, nodi\, da\, visitare$

3 $P = BFS\,(t, SS) \qquad // \, nodi\, pivot$

4 $Q.add(t)$

```
while (Q ≠ ∅)
  u = DEQUEUE(Q)
  V.add(u)
  for each v ∈ NEARNODES(u)
    if v ∉ V ∪ P
      if BFS(v) ⊂ P
        ENQUEUE(Q, v)
      else
        for each n ∈ BFS(v)
          for each m ∈ P
            if ISCHILD(n, m)
              P.remove(m)
              P.add(n)
return P
```

Come si può notare l'algoritmo fa uso di tre funzioni:

- ***ENQUEUE(Q:coda)*** e ***DEQUEUE(Q:coda)*** sono funzioni standard delle code per l'estrazione del nodo in testa e l'aggiunta di un un nodo alla fine della coda;
- ***ISCHILD(n: nodo,m: nodo)*** è una funzione che controlla se il nodo n (parametro) sia figlio del nodo m, cioè se sia possibile raggiungere m da n e non sia vero l'inverso e restituisce un booleano;
- ***BFS(n:nodo)*** è un algoritmo ausiliare molto importante che esegue una BFS semplice fermandosi al livello nel quale incontra il primo supersense ed estraendo tutti i supersense del livello: a questi applica dei filtri per ridurne il numero cercando di mantenere solo quelli più spe-

cifici richiamando la funzione ISCHILD per ogni coppia di supersense e mantenendo tra quelli rimasti i supersense a maggiore distanza dal nodo "entity".

Il nodo "entity" è un nodo speciale in quanto tutti i supersense individuati hanno una relazione is-a, diretta o indiretta, con esso e la distanza da esso può darci una stima, seppur grossolana, sulla specificità del lemma.

L'algoritmo è stato testato su 4,4 milioni di nodi, cioè tutti quelli che hanno Wikipedia come sorgente, e ha restituito almeno un supersense per 2,9 milioni di nodi ottenendo quindi una copertura di circa il 66%. I nodi non coperti dall'algoritmo sono nodi che o non hanno relazioni is-a o le hanno ma provengono da sorgenti considerate "insicure": considerare questi ultimi avrebbe inserito rumore nel classificatore in quanto le annotazioni sarebbero state meno precise.

3.3 Classificazione

In questa sezione viene illustrato come il sistema procede durante la fase di classificazione: vi è una fase iniziale in cui vengono creati i database di frasi per ogni supersense (3.3.1) generalizzando ogni link di Wikipedia (3.2), una fase di creazione di modelli (3.3.2) in cui vengono estratti i sensi per ogni parola e costruiti i modelli con cui istruire il classificatore e infine una fase di valutazione i cui risultati verranno presentati nel capitolo 4.1.

3.3.1 Creazione Training Set

Per costruire i databases viene sfruttato un dump statico di Wikipedia (datato Novembre 2014), ovvero una copia di tutte le pagine Wikipedia in formato HTML rilasciato periodicamente da Wikimedia Foundation.
Nella prima fase ogni articolo di Wikipedia viene suddiviso in frasi: per eseguire questo task è stato utilizzato un approccio generico basato su BabelNet cosicché sia indipendente dalla lingua e facilmente adattabile.
Da BabelNet viene estratto un insieme di parole $\mathcal{W}$ appartenenti alla lingua in esame che terminano con segni di interpunzione usati anche come indicatori di terminazione di frasi (punto, punto esclamativo, punto interrogativo, etc.); $\mathcal{W}$ viene usato come insieme di controllo su ogni "frase candidata", cioè che presenta un segno di interpunzione finale e la prima lettera della frase successiva maiuscola: se questa termina con una parola non presente in $\mathcal{W}$ allora il testo individuato viene considerato una frase, altrimenti si continua la ricerca della terminazione e si ripete il passaggio.

Per ogni supersense dell'insieme $\mathcal{SS}$ (trattato in 3.2) viene creato un database che conterrà le frasi con lemmi annotati che hanno quel supersense come iperonimo.
La caratteristica di Wikipedia che viene sfruttata da questo sistema per annotare il testo con i supersense di BabelNet e renderlo disponibile nei databases è il meccanismo dei link interni. Un link è un collegamento diretto ad un'altra pagina di Wikipedia, diretto o tramite *redirection*; questi link possono essere visti come **annotazioni** dei sensi di una parola, ovvero come il prodotto della disambiguazione della parola da parte di Wikipedia stessa; infatti per ogni senso di un dato lemma Wikipedia ha tipicamente una pagina e la raccolta di tutti i sensi avviene nelle cosiddette *pagine di disambiguazione*

che contengono tutte le pagine con i sensi di quel determinato lemma. Poiché i link sono creati e controllati manualmente essi garantiscono un'elevata precisione.
A titolo di esempio il testo html:

```
La moneta della <a href=‘‘Sierra_Leone’’>Sierra Leone</a> è il
<a href=‘‘Leone_sierraleonese’’>Leone</a>.
```

ci mostra, navigando nel link a cui punta, che la prima occorrenza della parola "leone" indica lo Stato della Sierra Leone mentre la seconda una moneta: se riuscissimo a estrarre questa informazione potremmo istruire il sistema affinché riconosca la prima occorrenza come uno Stato e la seconda come una moneta.

Per ogni frase individuata nella prima fase si considerano i link interni e per ognuno di essi si interroga BabelNet cercando il synset corrispondente e lo si generalizza; se il nodo risulta generalizzabile con uno o più supersense la frase che contiene il link associato viene copiata nei database corrispondenti. L'insieme dei databases così creati verrà utilizzato in fase di training trattata in 3.3.2 e rappresenta uno degli output desiderati del sistema descritti nella sezione 2.4.
Di seguito sono indicati i 40 supersense più frequenti in Wikipedia con il rispettivo numero di frasi nel database associato:

Supersense	**Frasi**	**Supersense**	**Frasi**
Human	8.8mln	Accolade	397525
Nation	3.5mln	War	374330
City	2.7mln	Region	370807
Company	1.4mln	River	343607
Province	1 mln	Village	328539
Team	1mln	Island	318964
Capital	1 mln	Song	307357
Organization	944269	Fictional Character	304793
University	921281	Architectural Structure	302476
Territory	860099	Person	289696
Municipality	786943	Chemical Compound	280056
RockBand	655612	Newspaper	267319
Film	651887	Magazine	256179
Biological Group	637754	Book	255146
Television Program	631412	School	254828
Town	592429	Road	232494
Community	533802	Authority	226600
Language	519385	Brand	218136
Political Organization	500380	League	210387
Album	426851	Profession	201089

3.3.2 Apprendimento automatico

Per istruire il classificatore è stato utilizzato un apprendimento supervisionato basato su classi: questo permetterà di classificare anche parole che non hanno "annotazioni" in Wikipedia o che ne hanno poche superando quindi

uno dei limiti degli approcci basati su Wikipedia. Per ridurre il rumore dato dalla presenza di diversi lemmi sotto la stessa classe, il sistema viene istruito innanzitutto con esempi basati su parola e solo in seguito vengono aggiunti esempi class-based sino a raggiungere il numero prefissato di esempi necessari (30000).

La fase di classificazione può essere divisa in quattro steps: estrazione dei significati, calcolo della loro distribuzione, costruzione del modello e classificazione.
Nella **prima fase** dato un lemma, che definiamo *target*, vengono estratti i significati più frequenti tramite BabelNet. L'estrazione avviene selezionando tutti i synsets provenienti da WordNet e, se questi sono di numero inferiore a 10, quelli con il più alto numero di connessioni semantiche in BabelNet. I nodi così individuati vengono generalizzati e i supersense prodotti aggiunti nell'insieme $\mathcal{CP}$ dei supersense potenziali per quel lemma. Questo ci permette di ridurre il numero di classi con cui istruire il classificatore e rendere il problema più trattabile.

Nella **seconda fase** il sistema considera le occorrenze della parola target nei link interni di Wikipedia che, una volta associati a un Babel Synset, vengono generalizzati con una delle classi dell'insieme $\mathcal{CP}$. Dalle occorrenze viene calcolata la frequenza dei significati per lemma; ad esempio la parola "plane" ha la seguente distribuzione di supersense:

Supersense	%
mathematical object	41,58
state	13,78
airplane	12,46
biological group	11,72
mechanical device	7,10
tool	6,85
tree	5,12
aircraft	1,40

Nella **terza fase** il classificatore viene istruito con le frasi dei link della fase precedente, selezionandole in base alla distribuzione calcolata precedentemente. Ipotizzando che l'insieme di training contenga 30000 esempi, nel caso precedente il classificatore verrebbe istruito con il 12000 esempi del supersense "matematical object", 3900 di state e così via. Qualora uno dei supersense abbia una percentuale di 0%, cioè non ha esempi in Wikipedia in cui il lemma è annotato, il sistema fissa un numero predefinito di esempi con il quale istruire il classificatore.

L'output di questa fase è un modello associato al lemma target: in particolare essendo basato su SVM il sistema genera per ogni classe del lemma un classificatore booleano con esempi positivi e negativi e da questi calcola il modello o funzione obbiettivo. Matematicamente questa funzione, dato un insieme di caratteristiche $\mathcal{C}$, restituisce un supersense dell'insieme $\mathcal{SS}$, quindi sia $\mathcal{C}$ l'insieme delle caratteristiche (ad esempio POS Tag parola precedente, POS Tag parola successiva, combinazione parole etc.) di carnalità n, A_i l'elemento del contesto della frase afferente alla caratteristica i e $\mathcal{SS}$ l'insieme

dei supersense, il modello prodotto è una funzione del tipo:

$$f : Dom(A_1), Dom(A_2), ..., Dom(A_n) \rightarrow SS$$

Nella **quarta** ed ultima fase viene fornito in input al classificatore il testing set e per ogni frase, se il classificatore ha un modello per un lemma della frase, produce una previsione sulla classe di quel lemma o alternativamente una distribuzione di probabilità delle classi associati al lemma.

3.3.3 Generazione nuovo testo annotato

Con i modelli sviluppati in precedenza può essere prodotto nuovo testo annotato ai supersense di BabelNet semplicemente fornendo in input al tagger testo libero. L'idea per eseguire questo task è usare come input del sistema tutti gli articoli di Wikipedia in modo che, per ogni lemma non annotato di cui il sistema ha un modello, possa produrre un annotazione.
Per ogni frase individuata nella prima fase si considerano i lemmi classificati: per ognuno di essi la frase che lo contiene viene copiata in un database associato al supersense e ordinato per percentuale di sicurezza del classificatore. L'insieme così ottenuto può essere tagliato a una certa altezza o filtrato in modo da estrarre le annotazioni più affidabili. Rispetto al primo insieme di annotazioni, ottenute nella sezione 3.3.1, queste sono meno precise ma se filtrate adeguatamente potrebbero essere usate come training set per lo stesso sistema, rendendo in un certo senso il sistema autonomo e in grado di apprendere da se stesso. Un esempio di testo annotato si trova nel prossimo capitolo nella figura 4.1.

Capitolo 4

Valutazione del sistema

In questo capitolo vengono illustrati i risultati ottenuti dal sistema (4.1), la sua accuratezza e un confronto con alcune baseline costruite ad hoc. Vengono fatti inoltre brevi cenni all'output, ovvero al testo annotato dal supersense tagger e alcune conclusioni che possiamo trarre da esso.

4.1 Risultati

In questa sede è stato usata la tecnica di valutazione *Hold Out* dividendo i dati in due partizioni. Per ogni lemma il 70% delle sue annotazioni è stato usato nel training set mentre il 30% per il testing set; la tecnica utilizzata implica che le stime qui riportate siano conservative dato che il modello finale prevede l'uso del 100% dei lemmi annotati in fase di training. Per comprendere meglio quali componenti hanno avuto peso maggiore nei risultati abbiamo utilizzato le seguenti baseline:

- **Class-based**: sono stati omessi dal training set gli esempi che avevano il lemma target annotato, istruendo il classificatore esclusivamente con esempi class-based.

- **Most Frequent Class (MFC)**: il training set non subisce modifiche mentre l'outpt del processo di classificazione è sempre la classe più frequente per il lemma target.

Non sono state prese in considerazione altre baseline, come quella word-based, in quanto i supersense coinvolti sarebbero diminuiti in numero quindi avrebbero prodotto risultati migliori in percentuale di accuratezza ma meno reali e applicabili.
Di seguito vengono mostrate 20 parole polisemiche selezionate manualmente, considerando quelle con il maggior numero di sensi per parola e con una distribuzione di essi più omogenea, in modo da avere risultati più veritieri possibili.

lemma	**Class-based**	**MFC**	**Tagger**
air	86%	60%	92%
argument	47%	70%	71%
arm	76%	59%	87%
bar	57%	30%	66%
body	79%	80%	82%
case	93%	51%	95%
chair	53%	36%	72%
change	43%	71%	71%
channel	89%	70%	93%
circuit	78%	52%	83%
crane	90%	49%	92%
fish	91%	85%	93%
material	88%	73%	92%
move	98%	88%	95%
pilot	83%	59%	93%
plan	78%	38%	83%
plane	56%	33%	70%
post	46%	43%	76%
set	95%	82%	97%
shape	83%	69%	88%
Totale	75.45%	59.9%	84.55%

Come possiamo osservare sia l'approccio class-based che quello completo si comportano meglio della baseline basata sul senso più frequente ma questo era preventivabile avendo selezionato lemmi con distribuzione di sensi omogenea. L'accuratezza dell'approccio class-based è di poco minore rispetto

allo stato dell'arte ma se si considera, come vedremo in seguito, che il classificatore può essere migliorato notevolmente con la produzione di nuovo testo annotato e maggiori frasi per ogni supersense, allora il risultato può essere considerato competitivo.
Un altro aspetto interessante è la differenza tra un approccio puramente class-based e l'approccio congiunto word-based e class-based; mentre in alcune parole il gap è di solo qualche punto percentuale, in altre come "plane" e "chair" la differenza è maggiore del 10%, segno che la presenza di lemmi target annotati è fondamentale per la corretta classificazione dei sensi. L'accuratezza complessiva del classificatore testato su circa il doppio dei lemmi è stata del 89%, tuttavia questi numeri vanno contestualizzati poiché sono il frutto dell'applicazione su frasi di Wikipedia che coprono un numero limitato di classi. Questo porta, per esempio, a rilevare i falsi positivi e i veri negativi per le classi di WordNet (ad esempio) che non hanno il lemma annotato in Wikipedia ma non permettono di rilevare i veri positivi, non rendendo quindi l'accuratezza del tutto affidabile. Possiamo però trarre spunti dal loro valore e valutare il sistema usando altri metodi empirici come vedremo in seguito.

Si può notare dal prossimo esempio che il sistema lavora sufficientemente bene anche quando in Wikipedia non ci sono occorrenze del lemma annotato con un determinato supersense e quindi, come descritto in 3.2, il sistema seleziona un numero prefissato di esempi class-based relativamente basso rispetto agli altri supersense. A titolo di esempio analizziamo il caso del lemma "air".
Air ha la seguente distribuzione di supersense:

supersense	**distribuzione**
atmosphere	21,29%
melody	0,06%
substance	2,82%
location	0,03%
aviation	59,50%
medium	0%
rock band	15,65%
wind	0,66%

Come possiamo vedere il supersense "medium" non ha lemmi annotati in Wikipedia che vengono generalizzati con esso e ne ha pochissimi per "location" e "wind", tuttavia nel testo annotato dal tagger (come illustrato in 3.3.3) possiamo vedere che le frasi riferite a tali sensi siano per la maggior parte corretti.

Di seguito viene proposta una vista contenente le dieci frasi dove il classificatore è più sicuro sul significato del lemma "air" e lo ha annotato con "medium". In grassetto il lemma classificato.

*This contrasts with traditional terrestrial television , in which the television signal is transmitted over the **air** by radio waves and received by a television antenna attached to the television.*

*Local insertion is also used by cable and telephone company television providers , in which cable and telco headends insert advertisements for the cable system , promos for programs on other cable channels carried by the cable provider and commercials for local area businesses (such as car dealerships or furniture stores) at least twice each hour ; unlike most commercial broadcast stations , however , cable channels often run only 60 seconds of local commercial inserts each half-hour near the end of the first or second commercial break and are aired in place of national ads or network promos that **air** during that given time.*

*The point-to-point signal transmissions occur through the **air** over a terrestrial microwave platform rather than through copper or optical fiber ; therefore , fixed wireless does not require satellite feeds or local telephone service.*

*In electrical engineering and telecommunications , attenuation affects the propagation of waves and signals in electrical circuits , in optical fibers , and in **air** (radio waves) .*

*Although radio propagation through **air** is faster than light through optical fiber , wireless systems are often shared among many users and may suffer from latency incurred due to network congestion which can trigger bufferbloat related issues , or due to network protocols that introduce latency.*

*In some countries , programming aimed at adult audiences may also **air** during the late night hours , such as softcore pornography (in the United States , a handful of cable television channels such as Cinemax and HDNet have used this practice , but this is forbidden on American broadcast television ; an exception to this is if the broadcast signal is encrypted , this allowed subscription networks that transmitted over broadcast television in the 1970s and 1980s such as ON-TV to air pornographic films at night).*

*The company garnered media attention when they introduced 6G broadband services by rolling out its Air Fibre network that transmits and receives internet through the **air**.*

*Unlike KOMU-TV of Columbia , Missouri , it is not affiliated with any network (though it did **air** the Research Channel when local programming was not scheduled) and only utilizes cable TV channel 31 on Knology (formerly Sunflower Broadband) and channel 99 on ATandT U-Verse in Kansas City , Missouri to transmit its signal.*

*Mediacom continues to carry the network in their markets with 24-hour programming due to their direct fiber connection from IPTV in Johnston to their Des Moines headend , which distributes the three IPTV channels statewide ; the national satellite services carry the network 's over-the-air signal , thus also going off the **air** from midnight to 5 a.m.*

*Although radio propagation through **air** is faster than light through optical fiber , wireless systems are often shared among many users and may suffer from latency incurred due to network congestion , or due to network protocols that introduce latency.*

Qui invece quando il classificatore lo classifica come “wind”.

*Pacific air that follows strong west winds move over the area and during the summer month a tropical **air** stream flows north from the Gulf of Mexico . During summer ,*

*regions of Mediterranean climate are dominated by subtropical high pressure cells , with dry sinking **air** capping a surface marine layer of varying humidity and making rainfall impossible or unlikely except for the occasional thunderstorm , while during winter the polar jet stream and associated periodic storms reach into the lower latitudes of the Mediterranean zones , bringing rain , with snow at higher elevations.*

*The severe winds reported across the Midwest to the east of the center (although little or no rain fell in many of those areas) were as a result of a combination of factors , including the strength and size of Ike itself allowing for a strong pressure gradient and a well-defined structure , the location on the east side of the storm where the winds are usually stronger in a northward-moving system due to its forward motion , its fast forward motion of about , and the warm **air** ahead of the storm allowed the high winds aloft to reach the surface easier.*

*Kappen climate classification Dfa (in southern areas) and Dfb (in northern parts) with varying influences from **air** masses from other regions including dry , cold Arctic systems , mild Pacific air masses from the West , and warm , wet tropical systems from the south and the Gulf of Mexico.*

*For a month or so before and after the summer dry season , hot , dry **air** from the desert , drawn by low pressure , produces strong winds from the south or southeast that sometimes reach gale force.*

*The spring time is also a season that brings much precipitation to the Great Plains through the cold , dry **air** masses that interact with the **air** masses from the Gulf of Mexico , creating outbreaks of severe thunderstorms with heavy rainfall , high winds , hail , and tornadoes .*

*Low-intensity storms have hit the island , including in 1901 , which blew over 1 , 500 coconut trees , on September 16 , 1944 which caused the wreck of a Royal **Air** Force PBY Catalina , September 1990 which demolished the tent city then being constructed for United States Air Force bomber crews during Operation Desert Storm , and on July 22 , 2007 , when winds exceeded and over of rain fell in 24 hours.*

*In the autumn , the tropical monsoon flow dies down and as arctic **air** begins to approach it can combine with moisture from the Pacific Northwest to bring snowfall to the city November is Denver 's third snowiest month , and both the greatest snowfall from a single storm and daily snow depth on record occurred before the Winter Solstice.*

*The 2007 Midwest flooding , which affected the hilly Driftless area of southeast Minnesota was the result of a training pattern of storms mixing warm moist **air** from Tropical Storm*

Erin with cooler Canadian air , resulting in record 24-hour rainfall totals of up to , with a similar flooding event in 2010 as a result of the remnants of tropical storm Georgette in the eastern Pacific and Hurricane Karl in the Gulf of Mexico.

*It is subject to both cold Arctic **air** and hot , humid tropical air from the Gulf of Mexico.*

A questo file è stato applicato un filtro che seleziona le frasi solo dove il classificatore produce un gap tra il primo e il secondo supersense candidato maggiore del 5%. Tuttavia è possibile applicare ulteriori filtri per restringere ancora il campo e ottenere delle annotazioni sempre più precise, ad esempio aumentando il gap o determinando delle soglie minime di sicurezza da raggiungere per ogni lemma.

Un'ulteriore verifica sul funzionamento del sistema è stata effettuata controllando, per ogni insieme di frasi classificate con un determinato supersense, quali fossero le parole più frequenti. Questo ci ha permesso di avere un'idea approssimativa di quali sensi il sistema classificava correttamente e in quali aveva maggiori difficoltà.
Ad esempio per il lemma "crane" le 10 parole più frequenti per il senso "television program" sono:
{crane, series, show, season, role, Frasier, episode, character, television, TV}.
Possiamo intuire che per questo senso il classificatore si comporta abbastanza bene mentre se consideriamo la parola "cast" nel suo senso di "container" vediamo che le 10 parole più frequenti sono:
{cast, John, role, show, production, David, members, series, Michael, Robert}
e quindi il classificatore non sta classificando adeguatamente questo senso.
Questo ultimo caso ci mostra tutte le difficoltà del sistema allo stato attuale:

"cast" è infatti una parola che ha pochissimi link all'interno di Wikipedia e tutti indirizzati ad un unico senso (cast televisivo); gli altri supersense provengono da WordNet e non hanno abbastanza frasi per compensare la mancanza di esempi word-based impedendo al classificatore di avere un training set adeguato alla classificazione di questi supersense. Per risolvere questo problema rimandiamo alla prossima sezione.

4.2 Conclusione e sviluppi futuri

In questo lavoro di tesi è stato presentato un supersense tagger per la classificazione dei nomi con una tassonomia basata su BabelNet. Le sue componenti sono state scelte prendendo in considerazione gli studi di ricerca attuali e i metodi che si sono rivelati più efficaci per il trattamento di una grande quantità di dati:

- *It Makes Sense* è stato scelto in quanto, essendo stato costruito appositamente per il trattamento di testi, non richiede trasformazioni dei dati eccessive. Offre inoltre API in Java e permette il passaggio degli esempi anche in formato XML, rendendo la fase di classificazione agevole e allo stesso tempo accurata;
- *LibLinear* è adatto a situazioni con esempi maggiori di 10000. In questo caso ci ha permesso di utilizzare fino a 30000 esempi per training set;
- l'uso di *BabelNet* piuttosto che di WordNet ha permesso da un lato di offrire un framework potenzialmente multilingua e dall'altro di sfruttare Wikipedia come fonte di esempi tramite cui istruire il sistema;

- *Wikipedia* ha permesso di ottenere un testo annotato per il training set mediante BabelNet e di fornire al sistema un nuovo testo da annotare dopo aver costruito i modelli per ogni lemma.

Per sviluppare adeguatamente il sistema sono stati necessari degli steps intermedi. In questi si è definito e studiato l'insieme dei supersense di BabelNet, analizzato le relazioni della rete semantica e quali di queste potessero essere considerate affidabili per produrre annotazioni, e più in generale testato la validità di questa risorsa come fonte di conoscenza per la disambiguazione automatica. Il risultato di questa analisi è stato soddisfacente, seppur si è notato come possano essere ancora fatti dei miglioramenti che porterebbero la risorsa ad essere estremamente valida nel campo.
Si è anche esteso It Makes Sense sviluppando un nuovo estrattore di caratteristiche.
I supersense e il testo annotato con essi, ottenuto con l'applicazione dell'algoritmo di generalizzazione ai link di Wikipedia, potrebbero essere usati come base per futuri lavori su BabelNet, ad esempio sfruttando il testo prodotto come testing set. Quest'ultimo potrebbe inoltre ridurre il problema degli esempi in numero limitato tipici dell'apprendimento automatico supervisionato.
L'output del sistema di classificazione, adeguatamente filtrato, potrebbe essere usato come base per un supersense tagger che produce risultati e apprende dagli stessi, rendendo il sistema autonomo e in grado di migliorarsi da solo, sfruttando l'intera Wikipedia annotata per ogni lemma.
Per quanto riguarda l'accuratezza del sistema questa andrebbe ricalcolata con il sistema a pieno regime, quando alcuni punti descritti a breve saranno portati a termine, e su testing set più completi dove siano annotati anche i

supersense provenienti da WordNet. Tuttavia già allo stato attuale il valore ottenuto di $\sim 85\%$ è da considerarsi un'ottima base di partenza.
Tra le possibili applicazioni proposte del sistema le più utili sono a mio parere:

- *un supersense tagger multilingua* implementando però per ogni lingua un lemmatizzatore e POS Tagger che la supporti ed estendendo It Makes Sense in modo che usi questi strumenti;
- *l'estrazione di concetti chiave* da testi o l'individuazione dell'argomento, classificando i nomi del testo e valutando quali supersense hanno maggiore frequenza;
- *Integrazione in Babelfy*[1] o miglioramento dello stesso.

Infine ritengo il sistema notevolmente migliorabile, essendo ancora in una fase "alpha", nelle componenti,nei dati e nel funzionamento. Ad esempio è da valutare l'uso di Wikidictionary[2] come sorgente per i plurali dei lemmi in sostituzione dello strumento illustrato nella sezione 3.1.2: questo dovrebbe portare a un migliore riconoscimento dei plurali e ad un training set, per ogni parola, con un numero di frasi maggiore.
Migliorare le relazioni is-a di BabelNet , sopratutto rendendo le relazioni automatiche più affidabili e considerandole in questo sistema, aumenterebbe la copertura dei nodi possibili, attualmente di circa 2,9 milioni, permettendo di generalizzare molti link in più di Wikipedia. Anche questo permetterebbe di avere più esempi per ogni singola classe e di migliorare l'accuratezza del sistema.
Un raffinamento ulteriore potrebbe essere la costruzione di un grafo pesato

[1] http://babelfy.org/
[2] https://en.wiktionary.org

dei supersense in modo da rappresentare con i pesi la loro specificità tramite la distanza dal nodo radice "Entity", migliorando la discriminazione tra i supersense dell'algoritmo di generalizzazione (3.2.1).
Per risolvere il problema della sezione precedente sui supersense di WordNet, che hanno pochi o nessuna frase nel database, si potrebbero innanzitutto usare i BabelGloss, ovvero definizioni date da BabelNet sui lemmi provenienti da tutte le enciclopedie o usare le migliori annotazioni prodotte dal sistema attuale studiando un euristica che permetta di estrarre solo annotazioni affidabili. Un'altra possibilità è valutare l'uso di testo annotato (SemCor o testi di SensEval) quando questo è ancorato a sensi di WordNet o sue categorie.

Bibliografia

[1] George A.Miller. Wordnet: A lexical database for english. *Communications of the ACM*, 38(11):39–41, 1995.

[2] Treccani. iperònimo. `http://www.treccani.it/vocabolario/iperonimo/`.

[3] R. Navigli. Word sense disambiguation: a survey. *ACM Computing Surveys*, 41:1–69, 2009.

[4] G. Rigau R. Izquierdo, A. Suàrez. Word vs. class-based word sense disambiguation. *Journal of Artifical Intelligence Research*, pages 83–122, 2015.

[5] J. Giles. Internet encyclopaedias go head to head. *Nature*, 438|15, 2005.

[6] C. Legg O. Medelyan, D. Milne and Ian H.Witten. Mining meaning from wikipedia. *International Journal of Human-Computer Studies*, 67:716–754, 2009.

[7] James R. Curran. Supersense tagging of unknown nouns using semantic similarity. *ACL 2005*, pages 26–33, 2005.

[8] E. Agirre and P. Edmonds. *Word Sense Disambiguation: Algorithms and Applications*. Springer, 2006.

[9] B. Snyder and M. Palmer. The english all-words task. *Third International Workshop on the Evalutation of Systems for Semantic Analysis of Text*, pages 41–43, 2004.

[10] G. Rigau R. Izquierdo, A. Suàrez. An empirical study on class-based word sense disambiguation. *Proceedings of the 12th Conference of the European Chapter of the Assocation for Computational Linguistics*, 2009.

[11] E. Agirre and O. LopezDeLaCalle. Clustering wordnet word senses. *Proceedings of RANLP'03*, 2003.

[12] R. Navigli. Meaningful clustering of senses helps boost word sense disambiguation performance. *Proceedings of 21st International Conference on Computational Linguistics and the 44th annual meeting of the Association ofr Computational Linguistics*, pages 105–112, 2006.

[13] B. Decadt, V. Hoste, W. Daelemans, and A. van den Bosch. Gambl, genetic algorithm optimization of memory-based wsd. *Proceedings of ACL/SIGLEX Senseval-3*, 2003.

[14] R. Mihalcea. Using wikipedia for automatic word sense disambiguationt. *Proceedings of the Human Language Technologies 2007*, 2007.

[15] R. Mihalcea and A. Csomai. Linking documents to encyclopedic knowledge. *Proceedings of the 16th ACM Conference on Information and Knowledge Management*, pages 233–241, 2007.

[16] M. Ciaramita and M. Johnson. Supersense tagging of unknown nouns in wordnet. *Proceedings of IJCAI 2003*, 2003.

[17] M. Ciaramita and Y. Altun. Broad-coverage sense disambiguation and information extraction with a supersense sequence tagger. *Proceedings of the 2006 Conference on Empirical Methods in Natural Language Procesing EMNLP*, pages 594–602, 2006.

[18] G. Paaß and F. Reichartz. Exploiting semantic constraints for estimating supersense with crfs. *SDM 2009*, pages 485–496, 2009.

[19] G. Attardi, S. Dei Rossi, G. Di Pietro, A. Lenci, S. Montemagni, and M. Simi. A resource and tool for super-sense tagging of italian texts. *Proceedings of the 7th Language Resource and Evalutation Conference(LREC 2010)*, pages 17–23, 2010.

[20] N. Schneider, B. Mohit, K. Oflazer, and N. A Smith. Coarse lexical semantic annotation with supersenses: an arabic case study. *Proceeding of the 50th Annual Meeting of the Association for Computational Linguistics*, pages 253–258, 2012.

[21] Y. Tsvetkov, N. Shneider, D. Hovy, A. Bhatia, M. Feraqui, and C. Dyer. Augmenting english adjective senses with supersenses. *Proceedings of LREF*, pages 4359–4365, 2014.

[22] Y. Tsvetkov, E. Mukomel, and A. Gershman. Cross-lingual metaphor detection using common semantic features. *Meta4NLP*, page 45, 2013.

[23] P. Ye and T. Baldwin. Melb-yb: Preposition sense disambiguation using rich semantic features. *Proceedings of the 4th International Workshop on Semantic Evaluations*, pages 241–244, 2007.

[24] S. Tratz and E. Hovy. Isi: automatic classification of relations between nominals using a maximum entropy classifier. *Proceedings of the 5th International Workshop on Semantic Evaluation*, pages 222–225, 2010.

[25] B.Magnini and G. Cavaglià. Integrating subject field codes into wordnet. *Proceedings of LREC*, 2000.

[26] I. Niles and A. Pease. Towards a standard upper ontology. *Proceedings of the 2nd International COnference on Formal Ontology in Information Systems*, 2001.

[27] G. Rigau R. Izquierdo, A. Suàrez. Exploring the automatic selection of basic level concepts. *International COnference Recent Advances in Natural Language Processing*, pages 298–302, 2007.

[28] Rong-En Fan, Cho-Jui Hsieh Kai-Wei Chang, Xiang-Rui Wang, and Chih-Jen Lin. Liblinear: A library for large linear classification. *Journal of Machine Learning Research*, 9:1871–1874, 2008.

[29] Zhi Zhong and Hwee Tou Ng. It makes sense: A wide-coverage word sense disambiguation system for free text. *Proceedings of the ACL 2010 System Demonstrations*, pages 79–83, 2010.

[30] D. Conway. An algotithmic approach to english pluralization. `http://www.csse.monash.edu.au/~damian/papers/HTML/Plurals.html`.

[31] K. Toutanova, D. Klein, C. Manning, and Y. Singer. Feature-rich part-of-speech tagging with a cyclic dependency network. *Proceedings of HLT-NAACL 2003*, pages 252–259, 2003.

[32] R. Navigli, D. A. Jurgens, and D. Vannella. Semeval-2013 task 12: Multilingual word sense disambiguation. *Proc. of 7th International Work-*

*shop on Semantic Evaluation (SemEval), in the Second Joint Conference on Lexical and Computational Semantics (*SEM 2013)*, pages 222–231, 2013.

[33] Ronald L. Rivest Thomas H. Cormen, Charles E.Leiserson and C. Stein. *Introduzione agli algoritmi e strutture dati.* McGraw-Hill, 2009.